# 数据挖掘第二次项目

陈铭涛 16340024

May 21, 2019

## 1 CART 算法

CART 包含了分类决策树和回归决策树的算法,

# 2 Gradient Boosting

#### 3 Random Forest

# 4 代码实现

出于内存和并行化实现的考虑,本次项目选择了使用 Rust 语言实现, Rust 的 RAII 机制使得临时资源可以及时地释放,提升内存利用率,由编译器提供的静态检查可以避免多线程时线程不安全的情况,降低 debug 难度。

程序实现中使用的第三方库如下:

- 1. rayon: 提供基于迭代器的便捷地编写并行代码的方法
- 2. rand: 提供随机数生成
- 3. csv: 提供对 csv 文件的读取
- 4. indicatif: 提供命令行进度条实现
- 5. ndarray: 提供类似 numpy 的多维数组的操作
- 6. num-traits: 提供数值类型上的一些实用方法,如最大最小值等
- 7. log: 程序日志
- 8. pretty\_env\_logger: 程序日志输出
- 9. num\_cpus: 获取系统 CPU 核心数量

#### 5 并行化表现

## 6 验证

以下程序测试均在一台搭载 6 核 12 线程 CPU,运行 macOS 系统的笔记本电脑上运行。

验证的标准为  $R^2$ , 其计算方法如下:

$$\overline{y} = \frac{1}{n} \sum_{i=1}^{n} y_i,$$

$$SS_{tot} = \sum_{i} (y_i - \overline{y})^2,$$

$$SS_{res} = \sum_{i} (y_i - f_i)^2,$$

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$
(1)

其中  $y_i$  为第 i 个样本的实际观察值, $f_i$  为第 i 个样本的模型预测值。 $R^2$  的取值通常在 0 与 1 之间,越接近 1 代表预测值与真实值匹配程度越高。

使用 LightGBM 默认参数构建一个模型运行 3 折交叉验证进行对比:

```
In [6]: run_cross_validation(trains, labels, lgb.LGBMRegressor, params)

fit_time: [24.27433276 22.56340122 23.01793098]
   Average fit_time: 23.285222
   score_time: [10.66991425 9.20692468 8.52207994]
   Average score_time: 9.466306
   test_mse: [-0.33291203 -0.33487001 -0.34085721]
   Average test_mse: -0.336213
   train_mse: [-0.33630982 -0.33519583 -0.33240139]
   Average train_mse: -0.334636
   test_r2: [0.156102  0.15480654 0.15376245]
   Average test_r2: 0.154890
   train_r2: [0.15816958 0.15915648 0.15922097]
   Average train_r2: 0.158849
```

Figure 1: LightGBM 交叉验证结果

对单棵决策树进行交叉验证获得的结果如下: 在训练集上获得的平均  $R^2$  分数为 0.14947528261278345在验证集上获得的平均  $R^2$  分数为 0.143995380629807训练时间平均为 682423 ms.

Figure 2: 单棵决策树训练交叉验证结果

使用 Gradient Boosting 训练 150 步,设置单棵树最大生长至 2 层,进行交叉验证获得的结果如下:

在训练集上获得的平均  $R^2$  分数为 0.14595633826167811 在验证集上获得的平均  $R^2$  分数为 0.14329480642795986 训练时间平均为 223031 ms.

Figure 3: GBDT 训练交叉验证结果

使用 Random Forest 训练,决策树数量为 150,不限制决策树生长深度,进行交叉验证获得的结果如下:

在训练集上获得的平均  $R^2$  分数为 0.1496125066152948 在验证集上获得的平均  $R^2$  分数为 0.14889900127096856 训练时间平均为 444804 ms.

Figure 4: 随机森林训练交叉验证结果

四个训练中使用取样工具查看内存占用值分别如下:

1. LightGBM: 5.2G

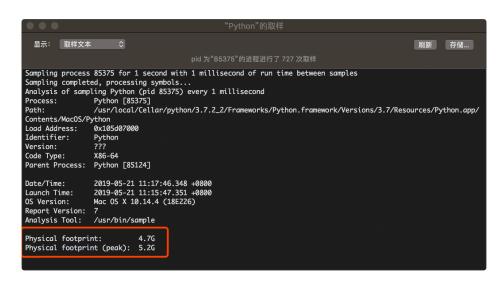


Figure 5: LightGBM 内存占用

2. 单决策树: 3.2G

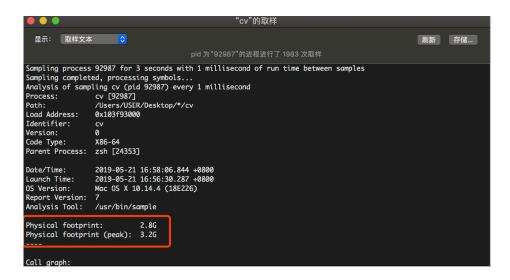


Figure 6: 单棵决策树训练内存占用

3. Gradient Boosting: 3.4G

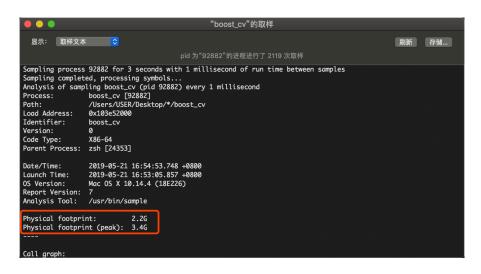


Figure 7: Gradient Boosting 训练内存占用

4. Random Forest: 2.1G

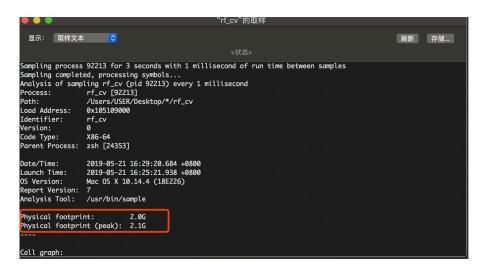


Figure 8: Random Forest 训练内存占用

# 7 Kaggle 分数

使用单棵决策树训练至 10 层后提交至 Kaggle 获得的分数为 0.16087:



Figure 9: 单棵决策树分数

使用 Gradient Boosting, Learning Rate 固定为 0.25, 基学习器最大训练至 3 层, 训练步数为 400 时的分数为 0.16957:



Figure 10: lr=0.25, GBDT